

Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Computación

Data Science

1966

UNIVERSIDAD

GUATEMALA



LABORATORIO I

SERIES DE TIEMPO

DEL VALLE DE

Estuardo André Castro Bonifaz – 23890

Juan Marcos Cruz Melara – 23110

André Emilio Pivaral López – 23574

Excelencia que trasciende

Catedrático: Boris Fernando Becerra Peláez

Sección: 30

Nueva Guatemala de la Asunción, 26 de julio de 2026

Índice

1. Resumen	1
2. Introducción	1
3. Análisis exploratorio	1
4. Partición y construcción de las series	4
5. Análisis de las series	5
5.1. Estacionariedad	5
5.2. Modelado	7
5.3. Predicción y comparación de métricas	8
6. Análisis comparativo	9
7. Conclusiones	10
8. Referencias	11

1. Resumen

En este laboratorio se analizó el ingreso mensual de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026 con técnicas de series de tiempo. Se realizó un análisis exploratorio del conjunto de datos, se dividió la información de forma cronológica en un setenta por ciento de entrenamiento y un treinta por ciento de prueba, y se construyeron siete series mensuales, la serie total obligatoria y seis series correspondientes a las categorías vía de ingreso y región de residencia. Para cada serie se evaluó la estacionariedad en media y en varianza, se determinó el número de diferencias mediante la prueba de Dickey-Fuller aumentada y se ajustaron modelos SARIMA, auto_arima, Prophet, Holt-Winters, suavizamiento exponencial simple y seasonal naive. Los modelos se compararon mediante el error absoluto medio, la raíz del error cuadrático medio y los criterios de información de Akaike y bayesiano. El principal hallazgo es que los modelos SARIMA logran el mejor ajuste dentro de la muestra pero el mayor error en la prueba, porque el entrenamiento termina en plena pandemia, mientras que modelos más flexibles como Prophet y el suavizamiento exponencial generalizan mejor sobre el periodo de recuperación.

2. Introducción

El turismo receptor es una fuente relevante de divisas y empleo para Guatemala, por lo que anticipar el volumen de viajeros resulta valioso para la planificación de capacidad, infraestructura fronteriza y campañas de promoción. El conjunto de datos utilizado contiene registros mensuales de ingreso de viajeros con variables de año, mes, vía de ingreso, frontera, país y región de residencia y tipo de viajero. Debido a que la categoría viajero excluye desde 2023 a los viajeros no turísticos de alta frecuencia, se utilizó como medida consistente en todo el periodo la suma de turistas y excursionistas para la serie total. Las dos categorías de análisis seleccionadas fueron la vía de ingreso, con las series aérea, terrestre y marítima, y la región de residencia según la variable Región dos, con las tres regiones de mayor volumen acumulado. Estas categorías ofrecen un buen contraste para responder las preguntas sobre estacionalidad, crecimiento, volatilidad e impacto de la pandemia.

3. Análisis exploratorio

La serie total abarca doscientos diez meses. El comportamiento temporal muestra una tendencia creciente sostenida entre 2009 y 2019, en la que el total anual pasó de 1.88 millones a 4.13 millones de viajeros, seguida de un colapso durante la pandemia y una recuperación posterior. El mínimo histórico se registró en mayo de 2020 con

9,779 viajeros y el máximo en diciembre de 2019 con 449,114 viajeros. La Figura 1 presenta la serie mensual y la Figura 2 el total anual, donde 2020 se resalta por la caída y 2026 por ser un año parcial con seis meses.




Figura 1. Total mensual de viajeros, suma de turistas y excursionistas, de 2009 a 2026.




Figura 2. Total anual de viajeros. El año 2020 aparece en rojo por la pandemia y 2026 en gris por ser parcial.

El perfil estacional promedio del periodo anterior a la pandemia, mostrado en la Figura 3, revela una estacionalidad anual marcada, con un máximo en diciembre cercano a 306 mil viajeros y un mínimo en febrero cercano a 186 mil, además de repuntes secundarios en marzo y julio asociados a Semana Santa y a las vacaciones de mitad de año. Esta estacionalidad de periodo doce es determinante para la elección de los modelos.




Figura 3. Perfil estacional promedio mensual del periodo 2009 a 2019.

En cuanto a los volúmenes acumulados, resumidos en la Figura 4 y en el Cuadro 1, los países de residencia con mayor participación son El Salvador, Guatemala y Estados Unidos. La aparición de Guatemala corresponde a residentes que retornan al país, y a partir de 2023 la variable país deja de representar países individuales para convertirse en agrupaciones de mercado, motivo por el cual esta variable no se usó para construir series. Por región de residencia domina América del Centro, seguida de América del Norte y Europa. La vía terrestre concentra la mayoría de los ingresos, seguida de la aérea y de la marítima. La frontera más utilizada es el aeropuerto La Aurora, seguida de las fronteras terrestres Valle Nuevo y San Cristóbal.




Figura 4. Volumen acumulado de viajeros por país, región de residencia, vía de ingreso y frontera.

Cuadro 1. Participación por categoría sobre el total acumulado de viajeros.

Categoría	Principales valores	Participación
País de residencia	El Salvador	31.0 %
	Guatemala	28.3 %
	Estados Unidos	13.5 %
Región de residencia	América del Centro	71.5 %
	América del Norte	17.9 %
	Europa	4.3 %
Vía de ingreso	Terrestre	61.2 %
	Aérea	36.5 %
	Marítima	2.4 %
Frontera	La Aurora	36.4 %
	Valle Nuevo	20.5 %
	San Cristóbal	10.3 %

El análisis de calidad de datos no encontró valores nulos ni filas duplicadas. La variable de cantidad de viajeros presenta valores fraccionarios, lo que indica que los datos provienen de una estimación o desagregación y no de un conteo entero. A nivel de la serie mensual total el único valor atípico según el criterio del rango intercuartílico es diciembre de 2019, que no es un error sino el máximo real previo a la pandemia. Los valores muy bajos de 2020 y 2021 no se marcan como atípicos porque ensanchan el rango intercuartílico, pero corresponden al choque de la pandemia.

4. Partición y construcción de las series

El conjunto se dividió de forma cronológica, reservando los primeros ciento cuarenta y siete meses para entrenamiento y los últimos sesenta y tres para prueba. El entrenamiento abarca de enero de 2009 a marzo de 2021 y la prueba de abril de 2021 a junio de 2026. Es importante notar que el entrenamiento termina en plena pandemia, por lo que los modelos aprenden la caída pero no la recuperación completa, lo que vuelve exigente el pronóstico y explica parte del error observado más adelante. Se construyeron siete series mensuales. La serie total se formó con la suma de turistas y excursionistas. Las series por vía de ingreso y por región de residencia se formaron con el total de todos los tipos de viajero, ya que la vía marítima corresponde casi por completo a cruceristas y se perdería si se restringiera a turistas y excursionistas. Todas las series tienen frecuencia mensual, inician en enero de 2009 y terminan en junio de 2026. La Figura 5 presenta el panel de las siete series con la marca del corte entre entrenamiento y prueba.




Figura 5. Panel de las siete series mensuales. La línea punteada marca el corte y la zona verde el entrenamiento.

5. Análisis de las series

5.1. Estacionariedad

Las siete series comparten la misma estructura, una tendencia creciente hasta 2019, un colapso en 2020 y una recuperación posterior, junto con una estacionalidad anual clara de periodo doce. La descomposición aditiva confirma estos componentes, como ilustra la Figura 6 para la serie total. Ninguna serie es estacionaria en media en su nivel original, ya que la media cambia con la tendencia y con el choque de la pandemia. Las series que caen casi a cero durante la pandemia, la vía aérea, la vía marítima y la región Europa, tampoco son estacionarias en varianza, pues la amplitud de las oscilaciones depende del nivel, por lo que se les aplicó una transformación logarítmica para estabilizar la varianza.




Figura 6. Descomposición aditiva de la serie total de entrenamiento.

La no estacionariedad en media se confirmó con la función de autocorrelación y con la prueba de Dickey-Fuller aumentada. La función de autocorrelación en el nivel decae muy lentamente, señal de memoria larga y de no estacionariedad, y al aplicar una diferencia se corta con rapidez, como muestra la Figura 7 para la serie total. La prueba de Dickey-Fuller sobre las series de entrenamiento arroja el número de diferencias regulares que resume el Cuadro 2. La mayoría de las series requiere una diferencia. La región América del Norte resulta estacionaria en su nivel y la vía marítima requiere dos diferencias sobre la escala logarítmica. Para las series estacionales se prevé además una diferencia estacional de periodo doce en los modelos SARIMA.




Figura 7. Funciones de autocorrelación y autocorrelación parcial de la serie total tras una diferencia.

Cuadro 2. Transformación y número de diferencias por serie según la prueba de Dickey-Fuller aumentada.

Serie	Transformación	Diferencias d
Total	ninguna	1
Vía aérea	logarítmica	0
Vía terrestre	ninguna	1
Vía marítima	logarítmica	2
Región América del Centro	ninguna	1
Región América del Norte	ninguna	0
Región Europa	logarítmica	1

5.2. Modelado

Para cada serie se ajustaron varios modelos SARIMA con órdenes distintos y se seleccionó el de menor criterio de Akaike, se ejecutó la función `auto.arima` que propone órdenes de forma automática, y se ajustaron los modelos Prophet, Holt-Winters, suavizamiento exponencial simple y seasonal naive. Los parámetros p y q se orientaron con las funciones de autocorrelación y autocorrelación parcial, mientras que el parámetro d proviene de la prueba de Dickey-Fuller. El orden propuesto por `auto.arima` resultó coherente con lo observado, con una parte estacional de periodo doce en la mayoría de las series.

El diagnóstico de residuos del mejor SARIMA, ilustrado en la Figura 8 para la serie total, muestra residuos aproximadamente centrados en cero, aunque la prueba de Ljung-Box detecta autocorrelación remanente en varias series, lo que sugiere que ningún modelo captura por completo la dinámica posterior a la pandemia. En términos de los criterios de información, los modelos SARIMA obtienen los menores valores de Akaike y bayesiano, es decir el mejor ajuste dentro de la muestra.




Figura 8. Diagnóstico de residuos del mejor modelo SARIMA de la serie total.

5.3. Predicción y comparación de métricas

El Cuadro 3 compara los seis modelos sobre la serie total. Se observa la tensión central del trabajo, el modelo SARIMA tiene el menor criterio de Akaike pero el mayor error en la prueba, mientras que Prophet, que no minimiza los criterios de información, obtiene el menor error absoluto medio y la menor raíz del error cuadrático medio. La razón es que el entrenamiento termina en marzo de 2021 y el SARIMA proyecta el nivel deprimido y la estacionalidad del confinamiento, en tanto que Prophet ajusta una tendencia más flexible que se adapta a la recuperación.

Cuadro 3. Comparación de modelos sobre la serie total. El error se calcula en el conjunto de prueba.

Modelo	MAE	RMSE	AIC	BIC
Seasonal naive	207,322	219,664	—	—
Suavizamiento exponencial	165,370	180,596	—	—
Holt-Winters	255,905	277,044	3,102	3,149
SARIMA (2,1,2)(1,1,1,12)	448,298	494,652	2,880	2,900
auto_arima (2,1,2)(2,0,1,12)	310,672	339,501	3,530	3,554
Prophet	132,304	139,549	—	—

El mismo patrón se repite en las demás series. El Cuadro 4 resume el mejor modelo de cada serie según la menor raíz del error cuadrático medio en la prueba. Prophet resulta el mejor en cuatro de las siete series, auto_arima en dos y el suavizamiento

exponencial simple en una. La Figura 9 muestra el pronóstico del mejor modelo para la serie total frente a los valores reales, donde se aprecia que el modelo capta el nivel de recuperación pero suaviza los picos estacionales.

Cuadro 4. Mejor modelo por serie según el error en el conjunto de prueba.

Serie	Mejor modelo	MAE	RMSE
Total	Prophet	132,304	139,549
Vía aérea	auto_arima (1,0,1)(1,0,1,12)	28,846	33,873
Vía terrestre	Prophet	54,280	71,294
Vía marítima	Prophet	783	1,644
Región América del Centro	Prophet	49,330	72,731
Región América del Norte	auto_arima (2,0,2)(1,0,0,12)	26,300	30,146
Región Europa	Suavizamiento exponencial	9,745	11,195





Figura 9. Pronóstico del mejor modelo de la serie total frente a los valores reales de prueba.

6. Análisis comparativo

Para responder las preguntas del análisis comparativo se cuantificaron cuatro indicadores por serie, la fuerza estacional y la fuerza de tendencia obtenidas de la descomposición sobre la ventana estable de 2011 a 2019, la tasa de crecimiento anual compuesta del mismo periodo, la volatilidad medida por el coeficiente de variación y la caída anual de 2020 respecto a 2019. El Cuadro 5 y la Figura 10 resumen estos indicadores.

Cuadro 5. Indicadores comparativos por serie.

Serie	Fuerza est.	Fuerza tend.	Crecimiento	Volatilidad	Caída 2020
Total	0.743	0.890	9.0 %	0.38	-74.4 %
Vía aérea	0.894	0.922	5.6 %	0.31	-72.3 %
Vía terrestre	0.619	0.877	12.6 %	0.49	-73.6 %
Vía marítima	0.688	0.278	5.5 %	1.15	-67.9 %
Región A. del Centro	0.665	0.900	11.5 %	0.45	-72.9 %
Región A. del Norte	0.945	0.830	4.7 %	0.41	-74.2 %
Región Europa	0.894	0.740	3.8 %	0.44	-71.8 %

**Figura 10.** Comparación de los cuatro indicadores entre las siete series.

En la categoría de vías de ingreso, la vía aérea presenta la mayor estacionalidad, la vía terrestre la mayor tendencia de crecimiento con una tasa anual del 12.6 por ciento, la vía marítima la mayor volatilidad con un coeficiente de variación de 1.15 por el carácter esporádico de los cruceros, y la vía terrestre fue la más afectada por la pandemia en términos de la caída anual, aunque la vía aérea tuvo el mínimo puntual más profundo. En la categoría de regiones, América del Norte muestra la mayor estacionalidad, América del Centro la mayor tendencia de crecimiento y también la mayor volatilidad, y América del Norte fue la más afectada por la pandemia con una caída del 74.2 por ciento.

7. Conclusiones

Los modelos SARIMA obtienen los mejores valores de los criterios de información, es decir el mejor ajuste dentro de la muestra, pero producen el mayor error en el

conjunto de prueba. Esto ocurre porque el entrenamiento termina en marzo de 2021, en plena pandemia, de modo que estos modelos proyectan el nivel deprimido y la estacionalidad del confinamiento. Los modelos Prophet, suavizamiento exponencial simple y `auto.arima` generalizan mejor sobre el periodo de recuperación y obtienen el menor error según la serie. Este resultado muestra que los criterios de Akaike y bayesiano no bastan para elegir un modelo de pronóstico cuando existe un quiebre estructural en la frontera entre entrenamiento y prueba, y que conviene validar siempre con el error fuera de la muestra.

Para el Instituto Guatemalteco de Turismo los hallazgos más útiles son los siguientes. La estacionalidad del turismo receptor es muy marcada, con un máximo en diciembre y un mínimo en febrero, lo que permite planificar capacidad, personal fronterizo y campañas de promoción por temporada. La recuperación posterior a 2021 superó el promedio del periodo de entrenamiento y estuvo impulsada por el turismo terrestre regional, que es el motor de volumen del país. La vía marítima, compuesta por cruceros, es la de menor volumen y mayor volatilidad, por lo que representa un nicho de alto riesgo y alta oportunidad que conviene monitorear de forma separada. Finalmente, para el pronóstico operativo después de choques como la pandemia resultan preferibles los modelos flexibles como Prophet, que se adaptan con rapidez a los cambios de nivel.

8. Referencias

- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2.^a ed.). OTexts. <https://otexts.com/fpp2/>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>